Technická správa – NUCAA projekt

Analýza závislosti príznaku M2 (accept)

Dataset `marks_complete.csv` ($N = 165\,355$, $n_{img} = 6\,167$)

8. marca 2026

Abstrakt

Dataset `marks_complete.csv` kombinuje geometrické a optické príznaky stôp zo súborov `.trk` so stĺpcom `accept`, ktorý pochádza zo stĺpca `M2` v súboroch `_m.csv`. Cieľom analýzy je zistiť, od akých príznakov závisí toto M2 rozhodnutie systému TASL. Dataset obsahuje 165 355 záznamov z 6 167 unikátnych obrázkov, z ktorých 35 956 (21.8 %) je označených ako `True` a 129 399 (78.2 %) ako `False`.

Obsah

1 Popis premenných **2**

2 Metodika **2**

3 Kľúčové zistenia **2**

3.1 Veľkosť stopy je primárny prediktor 2
3.2 Elongácia je druhý najdôležitejší prediktor 3
3.3 Zamietnuté stopy sú paradoxne kruhovitejšie 3
3.4 Rozhodujúce príznaky závisía od veľkosti stopy 3
3.5 Optická hustota má lokálny a menlivý efekt 4
3.6 Symetria mení charakter medzi skupinami 4
3.7 Logistická regresia 4

4 Odporúčaná sada príznakov pre ML **4**

1 Popis premenných

Tabuľka 1: Príznaky v datasete `marks_complete.csv`

Premenná	Jednotka	Popis
`maj`	px	Dĺžka hlavnej poloosi elipsy (veľký polomer)
`min`	px	Dĺžka vedľajšej poloosi elipsy (malý polomer)
`area`	px^2	Plocha stopy
`xt`	px	Alternatívna miera veľkosti stopy
`grey`	–	Priemerná optická hustota (jas) stopy
`a1`	–	Elongácia stopy (0 = kruh, vysoké = čiara)
`symm`	–	Symetria obrysu stopy
`conv`	–	Konvexita obrysu stopy
`sharp`	–	Ostrosť obrysu stopy
`focus`	–	Konštanta (hodnota 0 všade – vylúčená z analýzy)
`accept`	–	Cieľová premenná: hodnota `M2` z `_m.csv` `True` = akceptovaná, `False` = zamietnutá

Odvodená premenná použitá v analýze:

$$\texttt{circularity} = \frac{\texttt{min}}{\texttt{maj}} \quad (1 = \text{dokonalý kruh},\ 0 = \text{čiara})$$

2 Metodika

Analýza bola realizovaná v jazyku R s využitím balíčkov `tidyverse`, `pROC`, `moments` a `corrplot`. Použité metódy:

- **Deskriptívna štatistika** – porovnanie priemerov, smerodajných odchýlok a percentíl (p5, p25, p50, p75, p95) medzi skupinami True/False.
- **Stratifikovaná analýza** – rozdelenie stôp do veľkostných tried podľa `maj` a elongačných tried podľa `a1`; výpočet acceptance rate v každej triede.
- **Prahová analýza** – pre každý príznak bol hľadaný prah maximalizujúci F1 skóre pri binárnej klasifikácii accept/reject (exploratívne, bez train/test rozdelenia).
- **Point-biserial korelácia** – korelácia každého príznaku s `accept_bin` v rámci každej veľkostnej triedy zvlášť.
- **Analýza korelačných matíc** – výpočet rozdielov korelačných matíc (True mínus False) pre identifikáciu príznakov so zmenených vzájomných vzťahov.
- **Logistická regresia** – základný model a model s interakciami; hodnotené pomocou AUC (ROC krivka).

3 Kľúčové zistenia

3.1 Veľkosť stopy je primárny prediktor

Accepted stopy sú výrazne väčšie: priemerný `maj` je 29.3 px oproti 20.7 px u zamietnutých, `area` je 118.9 oproti 79.0 px^2.

Tabuľka 2: Acceptance rate podľa veľkostnej triedy

Trieda	**n**	**n accepted**	**Rate**
tiny (< 10 px)	35 558	1 487	4.2 %
small (10–20 px)	59 573	14 441	24.2 %
medium (20–40 px)	44 700	9 758	21.8 %
large (> 40 px)	25 524	10 270	40.2 %

Prahová analýza ukázala, že `min` $\geq$ 8.28 px zachytí až 99.3 % accepted stôp – stopy menšie ako $\approx$ 8 px sú teda takmer vždy zamietnuté. Závislosť nie je monotónna: trieda *medium* má nižší rate ako *small*, čo naznačuje zvýšenú prítomnosť artefaktov strednej veľkosti.

3.2 Elongácia je druhý najdôležitejší prediktor

Accepted stopy sú menej elongované (priemer `a1` = 0.207 vs 0.295).

Tabuľka 3: Acceptance rate podľa elongačnej triedy

Trieda	**n**	**n accepted**	**Rate**
round ($a1 < 0.1$)	52 570	13 158	25.0 %
slightly (0.1–0.3)	67 636	16 473	24.4 %
moderate (0.3–0.6)	26 415	3 992	15.1 %
highly ($a1 > 0.6$)	18 734	2 333	12.5 %

Závislosť je monotónna – čím elongovanejšia stopa, tým nižší acceptance rate. Vysoko elongované stopy fyzikálne zodpovedajú škrabanciam a lineárnym artefaktom.

3.3 Zamietnuté stopy sú paradoxne kruhovitejšie

Odvodená premenná `circularity` = `min`/`maj` ukázala, že zamietnuté stopy majú vyššiu circularitu (0.831 vs 0.753). Vysvetlenie: väčšina zamietnutých sú **malé kruhové artefakty** (prach, bodové defekty) kde `min` $\approx$ `maj`, ale s miniaturálnymi rozmermi. Skutočné jadrové stopy vznikajú pod rôznymi uhlami dopadu a majú prirodzenú elipticitu.

3.4 Rozhodujúce príznaky závisía od veľkosti stopy

Stratifikovaná point-biserial korelácia odhalila, že príznaky nemajú rovnaký vplyv vo všetkých veľkostných triedach:

Tabuľka 4: Dominantné prediktory podľa veľkostnej triedy

Trieda	**Dominantné príznaky (korelácia s accept)**
tiny (< 10 px)	`a1` (r=−0.109), `grey` (r=+0.090)
small (10–20 px)	`a1` (r=−0.133), `conv` (r=−0.064)
medium (20–40 px)	`grey` (r=−0.124), `symm` (r=−0.093)
large (> 40 px)	`symm` (r=−0.185), `sharp` (r=−0.153)

Toto je najdôležitejší nález: jednoduchý lineárny model bez stratifikácie tento efekt nepostihne.

3.5 Optická hustota má lokálny a menlivý efekt

Globálne je `grey` slabý prediktor (rozdiel priemerov: 124 vs 121). Lokálne však mení znamienko: u *tiny* stôp má kladnú koreláciu ($r = +0.090$) – svetlejšie malé objekty sú skôr zamietnuté (prach). U *medium* stôp má zápornú koreláciu ($r = -0.124$) – pravdepodobne efekt presýteného leptania.

3.6 Symetria mení charakter medzi skupinami

Analýza rozdielov korelačných matíc (True mínus False) ukázala, že u accepted stôp je **`symm` menej korelovaná s veľkosťou** ($\Delta r_{maj-symm} = -0.261$). U skutočných stôp je symetria nezávislá od veľkosti – leptanie postihuje malé aj veľké stopy stochasticky rovnako. U artefaktov väčšia veľkosť systematicky znamená nižšiu symetriu (napr. škrabance).

3.7 Logistická regresia

Základný logistický model (`maj, min, xt, a1, area, grey, symm, conv, sharp`) dosiahol AUC = 0.776. Model s fyzikálnymi interakciami (`maj:a1`, `maj:conv`, `min:a1`) dosiahol AUC = 0.691 – horšie, pretože neobsahoval `xt` a `area`.

Záporné koeficienty `xt` a `area` v základnom modeli sú artefaktom multikolinearity (`xt` $\approx$ `maj`, `area` je odvodená z `maj` a `min`). Premenná `sharp` je v základnom modeli štatisticky nevýznamná ($p = 0.473$).

4 Odporúčaná sada príznakov pre ML

Na základe analýzy odporúčame:

- **Použiť:** `maj, min, a1, conv, symm, grey`
- **Vylúčiť:** `xt`, `area` (redundantné – multikolinearita s `maj`/`min`), `sharp` (globálne nevýznamný), `focus` (konštanta)
- **Riešiť nevyváženosť tried** (22/78): SMOTE, class weights
- **Použiť nelineárne modely** (Random Forest, XGBoost) alebo hierarchický prístup – najprv klasifikácia veľkostnej triedy, potom accept/reject – keďže dominantné príznaky sa menia podľa triedy